

Adaptiv Läralgorithm

för Qmath Läroplattform

Bayesian Knowledge Tracing + Kunskapsgraf + IRT

Qmath | Februari 2026

Tekniskt algoritmförslag med konkreta kursexempel

1. Sammanfattning

Detta dokument beskriver en rekommenderad algorithm för att anpassa svårighetsgraden på matematikfrågor i Qmath-plattformen. Algoritmen kombinerar tre etablerade tekniker till ett kraftfullt system:

Rekommenderad algorithm: BKT-IRT-KG

1. Bayesian Knowledge Tracing (BKT) — estimerar studentens kunskapsnivå per koncept i realtid
2. Item Response Theory (IRT) — kalibrerar varje frågas svårighetsgrad baserat på all studentdata
3. Knowledge Graph (KG) — strukturerar prerequisite-beroenden mellan koncept inom kursen

Systemet använder ALL input: rätt/fel, svarstid, antal försök, partiella steg, hint-användning.

Algoritmen är designad för en kurs i taget, men arkitekturen tillåter skalning till fler kurser. Nedan förklaras varje komponent med konkreta exempel från TATA24 (Linjär Algebra), TATA32 (Diskret Matematik), TATA42 (Envariabelanalys 2) och TATA45 (Komplex Analys).

2. Kunskapsgraf (Knowledge Graph)

Kunskapsgrafen är fundamentet. Den definierar vilka koncept som finns i en kurs och vilka prerequisite-relationer som gäller. Grafen avgör i vilken ordning studenten får nya uppgifter och säkerställer att en student inte möter exempelvis kvadratiska former innan egenvärden behärskas.

2.1 Struktur

Varje nod i grafen är ett Knowledge Component (KC). Varje KC har:

Attribut	Beskrivning
id	Unikt ID, t.ex. "TATA24-KC-EIG"
name	Namn, t.ex. "Egenvärden och egenvektorer"
prerequisites	Lista av KC-id:n som måste behärskas först
difficulty_range	Intervall [min, max] för svårighetsgrad (θ -skala)
mastery_threshold	$P(K) \geq 0.85$ för att KC anses behärskad

2.2 Exempel: TATA24 Linjär Algebra

Baserat på tentamen 2026-01-17 identifieras följande kunskapsgraf (urval):

KC	Koncept	Prerequisites	Tentauppgift
KC1	Vektorer & skalärprodukt	— (grundnivå)	Uppg 1 (vinkel)
KC2	Plan & projektioner	KC1	Uppg 2 (närmaste punkt)
KC3	Linjer i $\mathbb{R}^3$	KC1	Uppg 3 (skärning)
KC4	Linjärt beroende/oberoende	KC1	Uppg 4 (spänna $\mathbb{R}^3$)
KC5	Linjära avbildningar	KC4	Uppg 5 (avb.matris)
KC6	Egenvärden/egenvektorer	KC4, KC5	Uppg 6
KC7	ON-baser (Gram-Schmidt)	KC1, KC4	Uppg 7
KC8	Nollrum & värderum	KC5, KC6	Uppg 8
KC9	Kvadratiska former	KC6, KC7	Uppg 9
KC10	Spegling & ortogonala avb.	KC6, KC7, KC9	Uppg 10

Grafvisualisering (prerequisite-träd)

KC1 (Vektorer) $\rightarrow$ KC2 (Plan) $\rightarrow$ KC7 (ON-baser) $\rightarrow$ KC9 (Kvadratiska former) $\rightarrow$ KC10 (Spegling)

KC1 $\rightarrow$ KC3 (Linjer)

KC1 $\rightarrow$ KC4 (Linjärt beroende) $\rightarrow$ KC5 (Linjära avb.) $\rightarrow$ KC6 (Egenvärden) $\rightarrow$ KC8 ($N(F) \cap V(F)$)

KC6 + KC7 $\rightarrow$ KC9 $\rightarrow$ KC10

Studenten låser upp KC9 först när BKT-estimatet för KC6 OCH KC7 passerar mastery_threshold.

3. Bayesian Knowledge Tracing (BKT)

BKT modellerar studentens dolda kunskapsläge ("kan" vs "kan inte") för varje KC som en Hidden Markov Model. Efter varje svar uppdateras sannolikheten $P(K_n)$ att studenten behärskar konceptet.

3.1 BKT-parametrar

Parameter	Symbol	Beskrivning	Typiskt värde
Prior knowledge	$P(L_0)$	Sannolikhet att studenten redan kan konceptet	0.1 – 0.3
Learn rate	$P(T)$	Sannolikhet att lära sig efter en övning	0.05 – 0.2
Guess	$P(G)$	Sannolikhet för rätt svar trots att man inte kan	0.05 – 0.25
Slip	$P(S)$	Sannolikhet för fel svar trots att man kan	0.02 – 0.10

3.2 Uppdateringsformel

Efter att studenten svarar på en fråga kopplad till KC med index k :

BKT Update — vid korrekt svar

$$P(K_n | \text{correct}) = P(K_n) \cdot (1 - P(S)) / [P(K_n) \cdot (1 - P(S)) + (1 - P(K_n)) \cdot P(G)]$$

Posterior efter learning transition:

$$P(K_{n+1}) = P(K_n | \text{obs}) + (1 - P(K_n | \text{obs})) \cdot P(T)$$

BKT Update — vid felaktigt svar

$$P(K_n | \text{incorrect}) = P(K_n) \cdot P(S) / [P(K_n) \cdot P(S) + (1 - P(K_n)) \cdot (1 - P(G))]$$

Posterior efter learning transition:

$$P(K_{n+1}) = P(K_n | \text{obs}) + (1 - P(K_n | \text{obs})) \cdot P(T)$$

3.3 Utökad BKT med rik data

Eftersom vi vill använda ALL studentinput utökar vi standard-BKT med följande signaler som modifierar $P(G)$ och $P(S)$ dynamiskt:

Signal	Effekt	Formel
Svarstid	Snabbt rätt → lägre $P(G)$, Långsamt rätt → högre $P(G)$	$P(G)' = P(G) \cdot \sigma(\alpha \cdot (t - t_{\text{median}}))$
Antal försök	Fler försök → högre $P(G)$ vid rätt	$P(G)' = P(G) + \beta \cdot (\text{attempts} - 1)$
Hint-användning	Hints höjer $P(G)$ markant	$P(G)' = P(G) + \gamma \cdot n_{\text{hints}}$
Partiell poäng	Steg-för-steg: delpoäng ger	$\text{obs} = \text{partial_score} \in [0,1]$ istället för

	mjukare uppdatering	binärt
Tidsfördröjning	Lång tid sedan övning → decay på $P(K)$	$P(K)' = P(K) \cdot e^{(-\lambda \cdot \Delta t)}$

4. Item Response Theory (IRT)

IRT kalibrerar varje frågas svårighetsgrad utifrån faktisk studentdata. Istället för att manuellt sätta svårighetsgrad låter vi modellen lära sig den från tusentals studentinteraktioner.

4.1 2PL-modellen

Vi använder 2-Parameter Logistic (2PL) IRT-modellen:

IRT 2PL — sannolikhet att student j svarar rätt på fråga i

$$P(\text{correct} \mid \theta_j, a_i, b_i) = 1 / (1 + e^{-(a_i \cdot (\theta_j - b_i))})$$

θ_j = studentens förmåga (ability) för det aktuella KC

b_i = frågans svårighetsgrad (difficulty)

a_i = frågans diskrimineringsförmåga (discrimination)

4.2 Koppling till BKT

BKT ger $P(K)$ per KC. Vi omvandlar detta till en θ -skala för IRT:

$$\theta_j = \text{logit}(P(K_j)) = \ln(P(K_j) / (1 - P(K_j)))$$

Detta ger en kontinuerlig ability-skala där $\theta = 0$ motsvarar $P(K) = 0.5$, $\theta = 2$ motsvarar $P(K) \approx 0.88$ (mastery), och $\theta = -2$ motsvarar $P(K) \approx 0.12$ (nybörjare).

4.3 Kalibrering av frågor — kursexempel

Varje fråga i systemet får IRT-parametrar. Här är exempel från de uppladdade tentorna, med uppskattad svårighetsgrad:

Kurs	Uppgift / Typ	b (svårighet)	a (diskr.)	KC-mappning
TATA24	Uppg 1: vinkel (Del A)	-1.5	1.2	KC1: Vektorer
TATA24	Uppg 9: kvadr. former (Del C)	2.0	0.8	KC9: Kv. former
TATA24	Uppg 10: spegling (Del C)	2.5	0.7	KC10: Spegling
TATA42	Uppg 1c: gränsvärde	-0.5	1.5	Taylor/L'Hôpital
TATA42	Uppg 6: potensserielösn. ODE	2.8	0.6	Potensserier + ODE
TATA45	Uppg 2: residykalkyl	1.0	1.0	Residyer
TATA32	Uppg 4b: derangemang	1.5	1.1	Kombinatorik

Notera: Dessa b-värden kalibreras automatiskt efter att tillräckligt med studentdata samlats in. Initialt sätts de manuellt baserat på pedagogisk bedömning.

5. Frågevalsalgorithm

Hjärtat i systemet: givet studentens nuvarande kunskapsprofil, vilken fråga ska presenteras härnäst? Vi använder en principbaserad approach som maximerar lärande.

5.1 Urvalsprocess (3 steg)

Steg 1: Bestäm tillgängliga KC

Filtrera bort KC vars prerequisites inte uppfyller mastery_threshold ($P(K) \geq 0.85$).

Filtrera bort KC som redan är fully mastered ($P(K) \geq 0.95$) — om inte review krävs.

Resultat: mängden av KC studenten bör arbeta med just nu.

Steg 2: Välj KC med högst prioritet

Prioritering baseras på:

- Lowest mastery first — KC med lägst $P(K)$ bland tillgängliga
- Spaced repetition bonus — KC som inte övats länge får bonus
- Exam relevance weight — KC som vägts tungt på tentan får bonus
- Formel: $\text{priority}(KC) = (1 - P(K)) + \lambda_{\text{decay}} \cdot \text{decay_factor} + \lambda_{\text{exam}} \cdot \text{exam_weight}$

Steg 3: Välj optimal fråga inom KC

Bland alla frågor kopplade till vald KC, välj frågan som maximerar information:

- Target difficulty: $b_i \approx \theta_i$ (frågan matchar studentens nivå)
- Fisher Information: $I(\theta) = a^2 \cdot P(1-P)$ — maximeras vid $b \approx \theta$
- Undvik redan sedda frågor (novelty bonus)

Resultat: studenten får alltid en fråga som varken är för lätt eller för svår.

5.2 Konkret exempel

En student i TATA24 har följande profil:

KC	P(K)	θ	Status
KC1: Vektorer	0.92	2.4	✓ Mastered
KC4: Linjärt beroende	0.88	2.0	✓ Mastered
KC5: Linjära avbildningar	0.65	0.6	⚡ Aktivt lärande
KC6: Egenvärden	0.30	-0.8	🔒 Prereq ej klar

Algoritmen väljer: **KC5 (Linjära avbildningar)** med en fråga vars $b \approx 0.6$ (matchar θ). KC6 är låst tills KC5 passerar mastery. Studenten får en medelsvår fråga om avbildningsmatriser — inte tentanivå ($b = 1.5$) utan en enklare variant.

6. Svårighetsgradssystem

Varje KC har frågor på flera svårighetsnivåer. Baserat på IRT-svårighet (b) definierar vi fem nivåer:

Nivå	b -intervall	Beskrivning	Exempel (TATA24, KC6)
1 ★	$[-3, -1]$	Ren begreppsfråga, igenkänning	"Vad är ett egenvärde?" eller "Är $\lambda=2$ egenvärde till A ?"
2 ★★	$[-1, 0]$	Standardberäkning med given metod	"Beräkna egenvärdena till $A = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}$ "
3 ★★★	$[0, 1]$	Standardproblem med fler steg	"Finn egenvärden och egenvektorer till 3×3 -matris" (som uppg 6)
4 ★★★★★	$[1, 2]$	Kombination av koncept, bevis	"Visa att A och B har samma egenvärden om $B = P^{-1}AP$ "
5 ★★★★★★	$[2, 3]$	Tentanivå Del C, kreativ tillämpning	"Finn bas för $N(F) \cap V(F)$ " (uppg 8) eller speglingsbevis (uppg 10)

7. Parameterskattning & Machine Learning

Alla parametrar i systemet lärs från data. Inget behöver vara perfekt från start — systemet förbättras kontinuerligt.

7.1 Kalibreringsprocess

Fas	Data som krävs	Vad som kalibreras	Metod
Cold start	0 studenter	Alla parametrar	Expertbedömning + priors
Fas 1	50–200 studenter	IRT-parametrar (a, b)	Marginal MLE (EM-alg.)
Fas 2	200–1000 studenter	BKT-parametrar per KC	Baum-Welch + grid search
Fas 3	1000+ studenter	Signal-vikter ($\alpha, \beta, \gamma, \lambda$)	Bayesian optimization
Continuous	Löpande	Alla parametrar	Online EM / A/B-test

7.2 Cold-start-lösning

Vid launch utan studentdata löser vi cold-start problemet genom:

- 1. Diagnostiskt test:** Studenten tar ett kort test (5–8 frågor) som spänner prerequisite-kedjan. Baserat på resultatet sätts initiala $P(K)$ -värden för alla KC.
- 2. Expert-priors:** BKT-parametrar sätts initialt baserat på pedagogisk erfarenhet. $P(L_0)$ sätts högre för grundkoncept (KC1: 0.3) och lägre för avancerade (KC10: 0.05).
- 3. Transfer priors:** Om studenten har data från en annan kurs (t.ex. TATA42 innan TATA45) överförs relevanta KC-estimat.

8. Systemarkitektur

Algoritmen integreras i Qmath enligt följande arkitektur:

Dataflöde (per student-interaktion)

1. Student → Svar (rätt/fel, tid, försök, steg, hints)
2. → BKT Engine: uppdatera $P(K)$ för relevant KC med utökade signaler
3. → IRT Engine: uppdatera studentens θ , eventuellt kalibrera fråga
4. → Knowledge Graph: kontrollera prerequisite-låsning
5. → Question Selector: välj nästa fråga (Steg 1-2-3 algoritmen)
6. → Student: presentera fråga med rätt svårighetsgrad

Latency target: < 200ms per frågevalsdykel

8.1 Databas-schema (kärna)

Tabell	Nyckelfält
knowledge_components	id, course_id, name, prerequisites[], mastery_threshold, difficulty_range
questions	id, kc_id, difficulty_b, discrimination_a, content, type, solution_steps[]
student_kc_state	student_id, kc_id, p_knowledge, theta, last_practiced, n_attempts, n_correct
interactions	id, student_id, question_id, correct, partial_score, time_ms, attempts, hints_used, timestamp
bkt_params	kc_id, p_init, p_learn, p_guess, p_slip, signal_weights{}

9. Algoritmjämförelse — Varför BKT+IRT+KG?

Vi har utvärderat flera alternativa algoritmer. Här är en jämförelse:

Algoritm	Svårighets-anpassning	Rik data-användning	Prerequisite-stöd	Tolkbarhet	Val
Elo rating	★★★★	★	★	★★★★	✗
Standard BKT	★★	★	★★	★★★★	✗
Deep Knowledge Tracing	★★★★	★★★★	★	★	✗
BKT + IRT + KG (vår)	★★★★	★★★★	★★★★	★★★★	✓

BKT+IRT+KG ger den bästa balansen: fullständig svårighetsanpassning via IRT, rik dataanvändning via utökad BKT, stark prerequisite-hantering via kunskapsgrafen, och hög tolkbarhet — vi kan alltid förklara för studenten varför en viss fråga presenteras.

10. Implementationsplan

Fas	Tidsram	Leverabler	Teknik
1	Vecka 1–3	Kunskapsgraf för 1 kurs + diagnostiskt test	JSON/GraphDB
2	Vecka 3–6	BKT-motor + basic frågeväljare	Python/TypeScript
3	Vecka 6–9	IRT-kalibrering + utökade signaler	pyBKT / pyirt
4	Vecka 9–12	A/B-test mot slumpmässig frågeordning	Analytics pipeline
5	Vecka 12+	Continuous calibration + fler kurser	ML pipeline

10.1 KPI:er att följa

Learning efficiency: antal frågor till mastery per KC (mål: 20% minskning vs. icke-adaptiv baseline).

Engagement: session length, return rate, completion rate.

Prediction accuracy: AUC-ROC för modellens förutsägelser (rätt/fel) — mål ≥ 0.75 .

Exam correlation: korrelation mellan plattformens mastery-estimat och faktiskt tentabetyg — mål $r \geq 0.6$.